第2章 统计数据的采集、整理和显示

统计实例

[年终审计时间]

某会计师事务所对20个客户样本的年终审计所花费的时间天数如下表所示。

请您：1. 采用适当的统计方法对该数据进行处理；

2. 您从这些数据中发现了何种统计规律?

年终审计时间（天）

12	14	19	18	15	15
18	17	20	27	22	23
22	21	33	28	14	18
16	13				

第二章 统计数据的采集、整理和显示

STAT

第一节 统计数据的采集

第二节 统计数据的整理

第三节 统计数据的显示

第一节 统计数据的采集（统计调查）

一、概念

- 统计调查：搜集**统计数据**的工作过程。
- 统计数据的类型：原始数据；次级数据（二手数据）

二、统计调查方案※

Why、Who、What、Way、When、How

（一）明确调查目的（Why）

一旦明确了调查目的，就知道调查谁，并进一步知道调查什么情况。

调查粉笔的
- 质量情况
  - 重量、书写流利程度
  - 折断率等
- 销售情况
  - 价格、销量
  - 品种、规格等

（二）确定调查对象与调查单位（Who）

1. 调查对象：调查研究的**总体**。　　确定总体范围

人口普查：**在中华人民共和国境内的自然人以及在中华人民共和国境外但未定居的中国公民，不包括在中华人民共和国境内短期停留的境外人员（第6次、第7次）**。前5次人口普查，普查对象是中华人民共和国境内的中国公民，第6次人口普查首次将居住在我国境内的港澳台和外籍人员纳入人口普查范围。

农村生育率调查：农村15～49岁的女性人口。

2. 调查单位：调查研究的**个体**。

（三）确定调查项目和调查表（What）

1. 调查项目：调查内容。
2. 调查表

一览表：多个单位共一张表。

某市商业局主要经济指标统计表

单位	销售额	库存额	利润
百货公司 纺织品公司 五交化公司 副食品公司			

第二章 统计数据的采集、整理和显示

单一表:　一个单位用一张表。

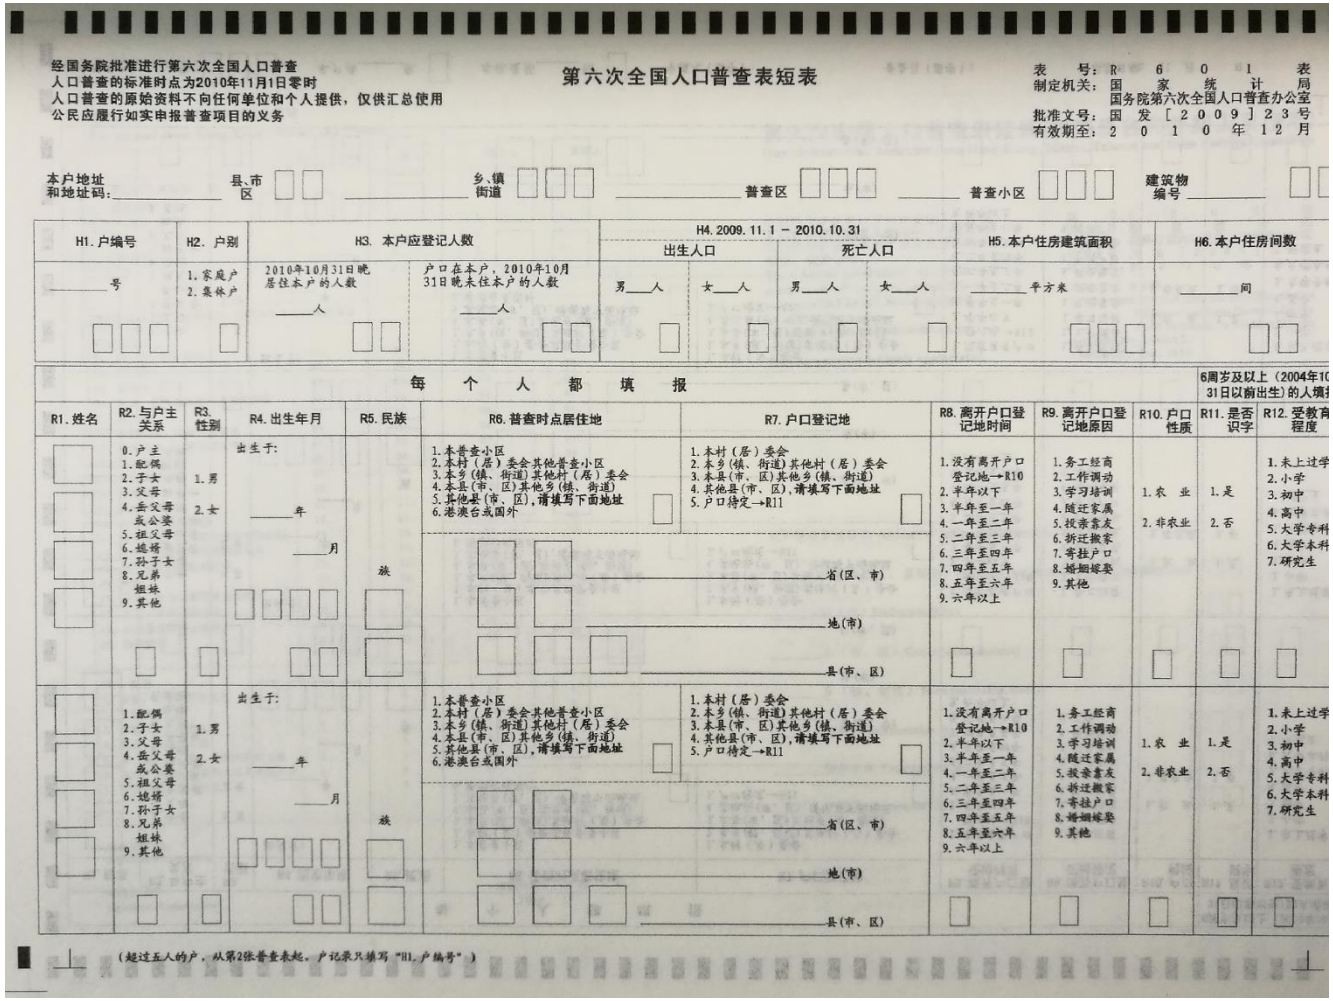

经国务院批准进行第六次全国人口普查
人口普查的标准时点为2010年11月1日零时
人口普查的原始资料不向任何单位和个人提供，仅供汇总使用
公民应履行如实申报普查项目的义务

第六次全国人口普查表短表

表　号：R　6　0　1　表
制定机关：国家统计局
国务院第六次全国人口普查办公室
批准文号：国发［2009］23号
有效期至：2010年12月

本户地址和地址码：_____ 县、市区 ☐☐ _____ 乡、镇街道 ☐☐☐ _____ 普查区 ☐☐☐ _____ 普查小区 ☐☐☐ 建筑物编号 _____ ☐☐

H1. 户编号	H2. 户别	H3. 本户应登记人数		H4. 2009.11.1 – 2010.10.31 出生人口		H4. 死亡人口		H5. 本户住房建筑面积	H6. 本户住房间数
_____号	1. 家庭户 2. 集体户	2010年10月31日晚居住本户的人数 _____人	户口在本户，2010年10月31日晚未住本户的人数 _____人	男___人	女___人	男___人	女___人	_____平方米	_____间

每个人都填报

6周岁及以上（2004年10月31日以前出生）的人填报

R1. 姓名	R2. 与户主关系	R3. 性别	R4. 出生年月	R5. 民族	R6. 普查时点居住地	R7. 户口登记地	R8. 离开户口登记地时间	R9. 离开户口登记地原因	R10. 户口性质	R11. 是否识字	R12. 受教育程度
	0. 户主 1. 配偶 2. 子女 3. 父母 4. 岳父母或公婆 5. 祖父母 6. 媳婿 7. 孙子女 8. 兄弟姐妹 9. 其他	1. 男 2. 女	出生于: _____年 _____月	族	1. 本普查小区 2. 本村（居）委会其他普查小区 3. 本乡（镇、街道）其他村（居）委会 4. 本县（市、区）其他乡（镇、街道） 5. 其他县（市、区），请填写下面地址 6. 港澳台或国外 _____省（区、市） _____地（市） _____县（市、区）	1. 本村（居）委会 2. 本乡（镇、街道）其他村（居）委会 3. 本县（市、区）其他乡（镇、街道） 4. 其他县（市、区），请填写下面地址 5. 户口待定→R11	1. 没有离开户口登记地→R10 2. 半年以下 3. 半年至一年 4. 一年至二年 5. 二年至三年 6. 三年至四年 7. 四年至五年 8. 五年至六年 9. 六年以上	1. 务工经商 2. 工作调动 3. 学习培训 4. 随迁家属 5. 投亲靠友 6. 拆迁搬家 7. 寄挂户口 8. 婚姻嫁娶 9. 其他	1. 农业 2. 非农业	1. 是 2. 否	1. 未上过学 2. 小学 3. 初中 4. 高中 5. 大学专科 6. 大学本科 7. 研究生
	1. 配偶 2. 子女 3. 父母 4. 岳父母或公婆 5. 祖父母 6. 媳婿 7. 孙子女 8. 兄弟姐妹 9. 其他	1. 男 2. 女	出生于: _____年 _____月	族	1. 本普查小区 2. 本村（居）委会其他普查小区 3. 本乡（镇、街道）其他村（居）委会 4. 本县（市、区）其他乡（镇、街道） 5. 其他县（市、区），请填写下面地址 6. 港澳台或国外 _____省（区、市） _____地（市） _____县（市、区）	1. 本村（居）委会 2. 本乡（镇、街道）其他村（居）委会 3. 本县（市、区）其他乡（镇、街道） 4. 其他县（市、区），请填写下面地址 5. 户口待定→R11	1. 没有离开户口登记地→R10 2. 半年以下 3. 半年至一年 4. 一年至二年 5. 二年至三年 6. 三年至四年 7. 四年至五年 8. 五年至六年 9. 六年以上	1. 务工经商 2. 工作调动 3. 学习培训 4. 随迁家属 5. 投亲靠友 6. 拆迁搬家 7. 寄挂户口 8. 婚姻嫁娶 9. 其他	1. 农业 2. 非农业	1. 是 2. 否	1. 未上过学 2. 小学 3. 初中 4. 高中 5. 大学专科 6. 大学本科 7. 研究生

（超过五人的户，从第2张普查表起，户记录只填写"H1. 户编号"）

（三）确定调查方法（Way）

根据研究目的、调查内容和调查对象特点确定。如全面调查、非全面调查等。

（四）确定调查时间（When）

调查资料所属时间和**调查工作**起止时间。

欲调查某市50家企业**2025**年的产值及**年末**职工人数情况，要求调查工作于次年1月1日开始，资料1月底之前上报。

（五）组织实施计划（How）

具体包括：调查人员的选择、组织与培训；调查文件、表格、调查员手册的印刷，调查宣传工作，必要调查工具的准备；调查经费的来源和开支预算等。

三、统计调查方法

（一）按调查对象所包括的范围分类（按调查单位的选取方法分）

1. 全面调查　普查、全面统计报表。
2. 非全面调查　抽样调查、 重点调查和典型调查。

（二）按搜集资料的方法分类

访问法、直接观察法、报告法等。

访问法　面访调查；电话调查；纸质问卷调查；电子问卷调查
观察法　直接观察法、实际测定法、行为记录法
报告法　统计报表制度

（三）按调查的组织形式分类

1.统计报表制度：“自上而下”布置调查任务，“自下而上”上报调查资料的统计制度（调查方法）。

2.专门调查：专门组织的调查。

普查、重点调查、抽样调查、典型调查

我国统计调查方法体系：以必要的周期性普查为基础，以经常性的抽样调查为主体，以重点调查、科学推算和全面报表为辅助。

四、统计调查的组织形式

（一）普查

1.定义：专门组织的一次性的全面调查。

中国：逢“0” 人口普查；逢“3” 第三产业普查；逢“5” 工业普查；逢“7” 农业普查 1次/10年；经济普查：逢“3”和“8”（2004年除外）。

2.方式：■组织专门机构和人员对调查单位直接登记；■颁发调查表格由填报单位填报。

3.应用范围与特点：用于摸清“家底”。范围广，数据全面详细；量大，时长，耗资。

4. 注意的问题

（1）规定统一标准时点：普查登记时所依据的统一时点。

[例]我国第四次人口普查的标准时间为1990年7月1日零时，第五次人口普查为2000年11月1日零时，第七次人口普查为2020年11月1日零时。

为什么要确定标准时点（间）？

标准时间的确定原则：人口流量小、气候较适宜的时刻，避开寒冬和炎夏，避开节假日和旅游季节。

（2）规定统一普查期限：同时进行，尽快完成。

（二）重点调查

1. 定义：对**重点单位**进行的调查。

重点单位：总体中**一小部分单位**的标志量占总体该方面标志总量的**比重足够大**。

2.应用范围与特点：用于只要求掌握总体**基本情况**。调查单位少，省时省力，时效性强。

3. 注意：调查对象须存在重点单位；不能推断总体总量

[例]研究企业销售收入。

如调查100个企业的销售收入，只调查销售收入总额居于前20位的就是**重点调查**。如上述企业，将其按销售收入总额大小分成5类，在每类中选一个企业调查，就是**典型调查**。典型调查的调查对象为调查总体中最具有调查特征的单位。

（三）抽样调查

概念

■按随机原则，从总体中抽取一部分单位组成样本进行调查，并根据样本特征值(样本指标)，对总体相应的特征值(总体指标)作出具有一定可靠程度的估计和判断。

■随机原则：同等可能性原则。

案例

制造商和广告代理商常常利用在购物中心的访谈来搜集消费者的消费习惯及广告效用等信息。他们认为，在购物中心选取样本既快速又省钱。

试问这种抽样方式符合随机原则吗?

“方便抽样”

五、统计误差

（一）定义

统计数据与客观事物真实数值之差。

（二）分类

1.按误差来源分：

- 登记性误差
  - 由于对所研究现象进行**观察、测量和记录等过程中的差错**而造成的误差。
  - 在任何统计调查中都有可能产生。
  - 如:登记重复/遗漏、记录错误、回答错误、测量不准确等。
- 代表性误差
  - **部分代表总体**而产生的误差
  - 是非全面调查所特有的

- **2.按误差性质分：**
- 随机误差
  - 由于**偶然原因**而发生的;
  - 不具有倾向性, 时大时小,时正时负;
  - 在大量数据汇总过程中可能被相互抵消（一定程度上）
- 非抽样误差
  - **除随机抽样之外**的各种原因而引起的（包括由于测量工具、测量方法或人为原因）；
  - 包括各种登记性误差和代表性误差中的非随机误差。

第二节　统计数据整理

一、定义

根据研究目的，对收集到的数据进行科学的加工处理，使之系统化、条理化、综合化，**由反映个体特征过渡到反映总体特征的工作过程。**　　**整理对象：**调查数据（原始、次级）

[例]统计目的：了解A地区100家工业企业的生产情况

$$\begin{cases} A_{001} \rightarrow 1000 \text{ 万元} \\ A_{002} \rightarrow 1250 \text{ 万元} \\ \vdots \\ A_{100} \rightarrow 750 \text{ 万元} \end{cases} \Rightarrow$$

1000+1250+　+750=50亿元

50亿/100=5000万元/家

二、步骤

（一）统计审核

1.逻辑推理法

例如：A：性别（女）、与户主关系（父子）；

B：某商场7月份零售了棉大衣10万件。

2.变量关系推算法

加总法、乘除法、平衡法、比较审查法

（二）统计分组

分开总体、了解差异。

例：企业→所有制、产值、职工人数、劳动生产率等；

人口→身高、文化程度、年龄、收入、职业等。

（三）统计汇总→形成分布数列

（四）统计制表

三、统计分组※

（一）概念与作用

1.概念： 将**统计总体**按一定的**标志**区分为若干个**性质不同**的组或类。 目的：在同质性的基础上研究总体的**内部差异性**。

分与合的过程：分 “总体”；合 “单位”

[例]对全班200名同学进行分组

A.按**专业**分 B.按**年级**分 C.按**性别**分 D.按**籍贯**分

2.作用： **揭示现象所属类型；解剖总体内在结构；分析现象之间关系**

[例]2000年中国人口**性别比**资料（以女性人口数为100）：

0 ~ 4：119.98
5 ~ 9：111.56
10 ~ 14：107.76
15 ~ 19：106.61
……
50 ~ 54：103.88
55 ~ 59：104.12
65 ~ 69：99.65
70 ~ 74：87.54
……
90 ~ 94：42.22

你看出什么规律或问题?

原因? **→个人角色、社会角色不同**

[例]2020年中国人口**性别比**资料（以女性人口数为100）：

0 - 4	111.07
5 - 9	113.67
10 - 14	114.89
15 - 19	115.90
20 - 24	112.40
25 - 29	110.32
30 - 34	105.84
35 - 39	105.87
40 - 44	105.30
45 - 49	104.03
50 - 54	101.64
55 - 59	100.28
60 - 64	101.16
65 - 69	96.63
70 - 74	95.00
75 - 79	89.74
80岁以上	73.97

（二）统计分组的原则及分组的种类

统计分组的关键：选择分组标志和划分各组界限

1. 分组的原则

（1）科学性

[例1]研究职工生活水平的变化情况

A.按职工工资水平分组

B.按职工家庭人均收入水平分组

[例2] 对12岁以下的儿童按年龄进行分组

表一

年龄	人数
0—3	
3—6	
6—9	
9—12	
合计	

表二

年龄	人数
0—1	婴儿
1—3	幼儿
3—6	学龄前儿童
6—12	小学
合计	

（2）穷尽性

（3）互斥性

→ 即：总体中任何一个个体都必须且只能归属于某一个组。

注意有标准线现象的组限划分。

[例]对某班同学按成绩进行分组，结果如下，何种正确（ ）

A. 成绩

55以下

55—65

65—75

…

B. 成绩

60以下

60—70

70—80

…

C. 成绩

60以下

60—68

70—80

…

D. 成绩

58以下

58—70

65—80

…

2. 分组种类

（1）按分组标志的特征分

- 品质分组：对人口按**性别**进行分组
- 数量分组：企业按产值分组、人口按年龄分组、住户按收入分组

（2）按分组标志的多少分

- 简单分组：只按**一个**标志分组。

[例]对中国人口进行简单分组

性别 { 男 / 女 }

职业 { 工人 / 农民 / 军人等 }

民族 { 汉 / 回 / 蒙等 }

- 复合分组：按两个或两个以上的标志重叠起来进行分组。

[例]对人口按性别、文化程度进行复合分组。

人口 { 男性 / 女性 } { 大学及以上 / 中学 / 小学 / 文盲半文盲 }

四、分布数列※

（一）概念及类型

1. 概念

■频数：分布在各组的个体数

■频率：各组次数占总次数的比重

都反映个体在各组分布的密集程度

■**分布数列**：将各组的频数或频率按分组的一定顺序加以排列。又称频数分布。

性别	人数 f	频率%
男生	20	25
女生	60	75
合计	80	100

年龄 x	人数 f	频率
17	6	0.12
18	14	0.28
19	18	0.36
20	9	0.18
21	3	0.06
合计	50Σf	1.00

频率分布能更好地体现总体分布特征

频率分布的两个基本性质：各组频率介于0和1之间；各组频率之和为1

分布数列是一种数据概括和简化。 简化的目的是消除“噪音”，显示总体分布的特征或规律。是数据整理的重要工具。

表现形式：表、图

满意程度	户数（f）
非常不满意	24
不满意	108
一般	93
满意	45
非常满意	30
合计	300（ f）

2. 类型 - 根据分组标志不同

（1）品质数列 →

（2）**变量数列**※ **按数量标志分组的结果**

变量**x**；次数**f**；频率。

（二）变量数列的种类

1.单项式数列：一个变量值代表一组。 **适用范围?**

2.组距式数列：以变量值的一个区间为一组 等距、异距数列。

所得：减少了组数，体现了组间差异，反映了总体分布特征和结构。

不足：丧失了原始信息，掩盖了组内差异； **适用范用?**

某地人口分布表

年 龄	人数（万人）
0—10	7
10—20	11
20—30	24
30—40	8
40—50	2
50 以上	2
合 计	54

A 班学生年龄分布表

年龄	人数	频率
17	6	0.12
18	14	0.28
19	18	0.36
20	9	0.18
21	3	0.06
合计	50	1.00

（三）组距式变量数列的编制

1. 全距： $R=X_{max}-X_{min}$ 某课成绩最高92分，最低24分

R=68分

2. 组限 ： 上限、下限 →组距数列中划定的各组数量界限。

要求：

■能区分事物的性质和总体分布特征

注意特定标准线情况。如贫困线上限的确定；奖惩式定额计划的制定。

■最小组下限应略低于总体的最小变量值，最大组上限应略高于总体的最大变量值

试卷成绩	数量	占比
40以下	3	4%
40~50	6	9%
50~60	10	10%
60~70	14	20%
70~80	18	30%
80~90	11	20%
90~100	7	10%

第二章 统计数据的采集、整理和显示

■对**连续变量**，只可编制组距式数列，且相邻组限必须重叠。**离散变量**不受此限制，但习惯上也采用组限重叠的方法。

■对**重叠组限**，组限值单位数遵循“上限不在内”原则。

[例] 第四组的取值范围[60、70)
第五组的取值范围[70、80)

■开口组组限根据相邻组的组距加以确定

试卷成绩	数量	占比
40以下	3	4%
40~50	6	9%
50~60	10	10%
60~70	14	20%
70~80	18	30%
80~90	11	20%
90~100	7	10%

第二章 统计数据的采集、整理和显示

3. 组距： i= U – L　**4. 组数**： **n = R/i**

[例]某班某门课的考试成绩最高为92分，最低为24分　R=68分。

i=10分，n = R / i = 68/10= 6.8　7组

成绩	组数
40以下	首组
40~50	第2组
50~60	第3组
60~70	第4组
70~80	第5组
80~90	第6组
90~100	末组

■**组距组数要正确确定，否则会掩盖事实真相！**

■**组距组数确定原则：能否划分各组的性质；差别能否准确清晰反映总体单位的分布特征**

实践经验： i　5、10或其倍数；　n 取5~7组。

第二章 统计数据的采集、整理和显示

STAT

表一：21 组

身高（cm）	人数（人）
84	1
85	1
87	1
91	2
94	1
95	1
96	1
97	1
99	1
101	2
…	…
合计	30

表二：2 组

身高（cm）	人数（人）
80—105	13
105—130	17
合计	30

表三：5 组

身高（cm）	人数（人）
80—90	3
90—100	7
100—110	13
110—120	5
120—130	2
合计	30

5. 组中值 = （U+L）/2

"本组平均水平" 。将组距缩小或组数增多，则两者之间的误差将缩小，组数趋于无限大时两者非常接近。

开口组**首组组中值=U - 邻组i/2**

开口组**末组组中值=L+邻组i/2**

身高（cm）	人数（人）
90 以下	3
90—100	7
100—110	13
110—120	5
120 以上	2
合计	30

注意组中值的假定条件：

第四组均匀分布时：111，113，115，117，119；

对称分布时：112，114，115，116，118。

开口组组中值的双重假定！

6.次数密度=次数/组距。 第三组：13人/10厘米=1.3人/厘米 **异距**

7. 变量数列编制的步骤

[例]已知30名同龄儿童的身高资料（cm）：

106，99，85，121，**84**，94，106，105，110，119，101，

95，91，87，105，106，109，118， 96 ，**128**，91，97，

105，111，111，107，103，101，107，106。

（1）将变量值按大小次序排列；

（2）计算全距：R=128–84=44（cm）；

（3）确定组数与组距；

令i=10cm， 组数n=44/10=4.4，取5组。

（4）编制变量数列。 （按身高对儿童分组）

某地30名同龄儿童身高分布统计表

表二

身高（cm）	人数（人）
90 以下	3
90—100	7
100—110	13
110—120	5
120 以上	2
合计	30

表一

身高（cm）	人数（人）
80~90	3
90~100	7
100~110	13
110~120	5
120~130	2
合计	30

（四）累计频数（频率）

向上累积（由小到大）：……以下（对应组的上限以下）；

向下累积（由大到小）：……以上（对应组的下限以上）。

审计时间	客户数	向上累积	向下累积
10~15	4	4	20
15~20	8	12	16
20~25	5	17	8
25~30	2	19	3
30~35	1	20	1
合计	20		

（五）分布数列的次数分布特征

1. 钟形分布

特征：中间大、两头小。

身高、体重、智商、纤维长度、细纱强度等。

- 对称分布：正态分布及t分布。
- 偏态分布（不对称分布）

右（正）偏 有极大值；

左（负）偏 有极小值。

第二章 统计数据的采集、整理和显示

年龄	人数
17	5
18	10
19	15
20	10
21	5
32	3
33	1
合计	49

年龄	人数
3	1
4	3
17	5
18	10
19	15
20	10
21	5
合计	49

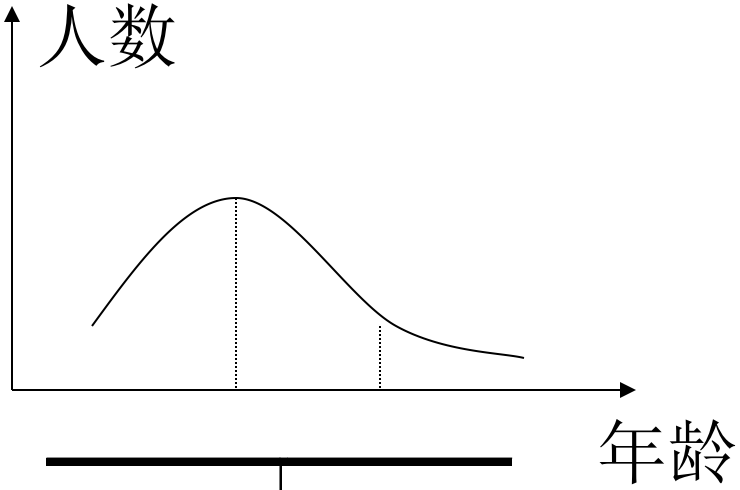

年龄	人数
17	5
18	10
19	15
20	10
21	5
合计	45

2. U形分布

分布特征：两头大中间小

人和动物分年龄段的死亡率；产品按使用时间的故障率。

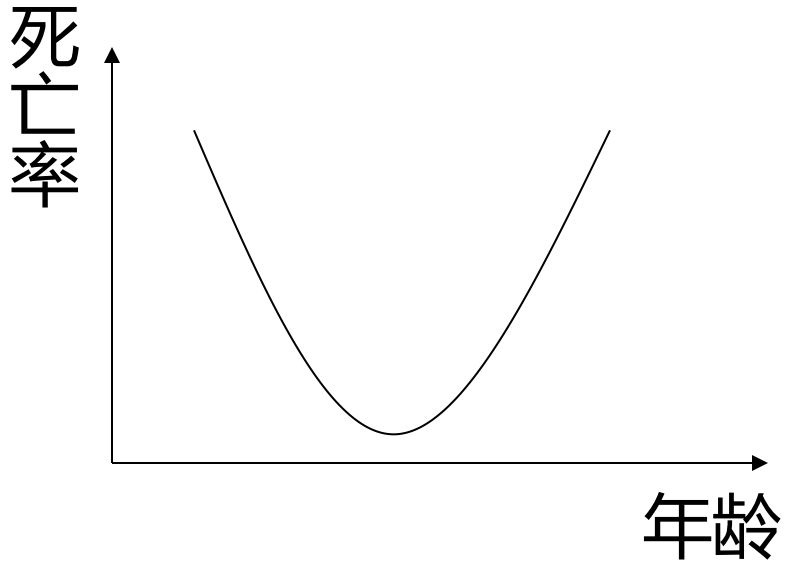

3. J形分布

分布特征：一边大一边小

- 正J分布：右大左小

  供给曲线。

- 反J分布：左大右小

  需求曲线、按结婚次数分组的人口数。

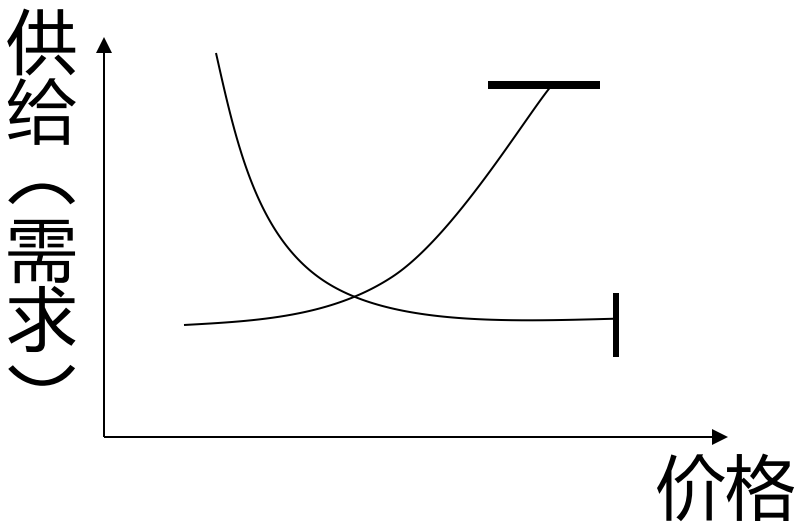

- 分布数列
  - 按分组标志
    - 品质数列
    - 变量数列
  - 按次数分布特征
    - 钟形分布数列
      - 正态分布
      - 偏态分布
        - 左偏分布
        - 右偏分布
    - U形分布数列
    - J形分布数列
      - J形
      - 倒J形
  - 按分组形式
    - 单项式数列
    - 组距式数列
      - 等距数列
      - 异距数列

第三节 统计数据的显示

用图或表来描述现象的数量特征

一、统计表 - - 表现经过整理的统计数据的表格

(一)基本结构

(二)编制规则

1.选择合适的总标题。→时间、空间、总体、指标

2.主宾词栏各归其后，相互对应。

3.表上下两端用粗实线或双线封口，左右两端一般不封口。

4.表中数字应保持同一精确度、整齐，要注明计量单位。

5.列数多时，加设编号。

6.数据栏不能有空白。

第二章 统计数据的采集、整理和显示

表头

2015 - 2016年农村居民按东、中、西部及东北地区分组的人均可支配收入

列标题

项目	单位	2015年	2016年
东部地区	元	14297.4	15498.3
中部地区	元	10919.0	117
西部地区	元	9093.4	99
东北地区	元	11490.1	122

行标题

数字资料

资料来源：《中国统计年鉴2017》

二、统计图

（一）直方图

宽 i; 高 f

试卷成绩	数量	占比
20~30	1	1%
30~40	2	3%
40~50	6	9%
50~60	10	10%
60~70	14	20%
70~80	18	30%
80~90	11	20%
90~100	7	10%

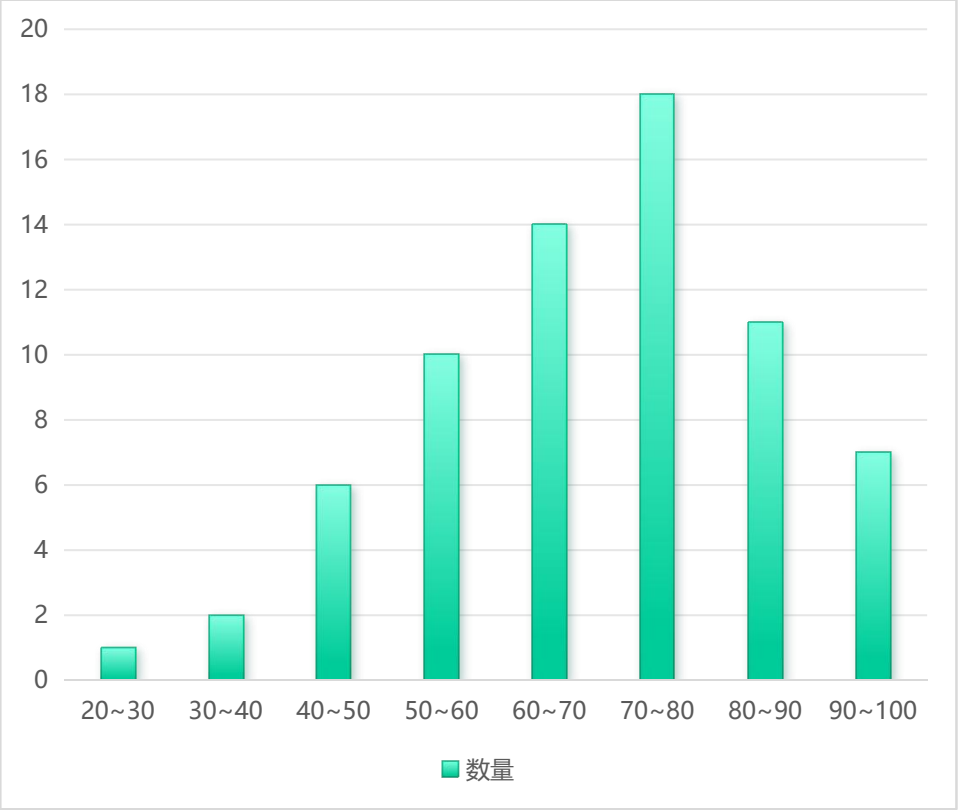

（二）折线图

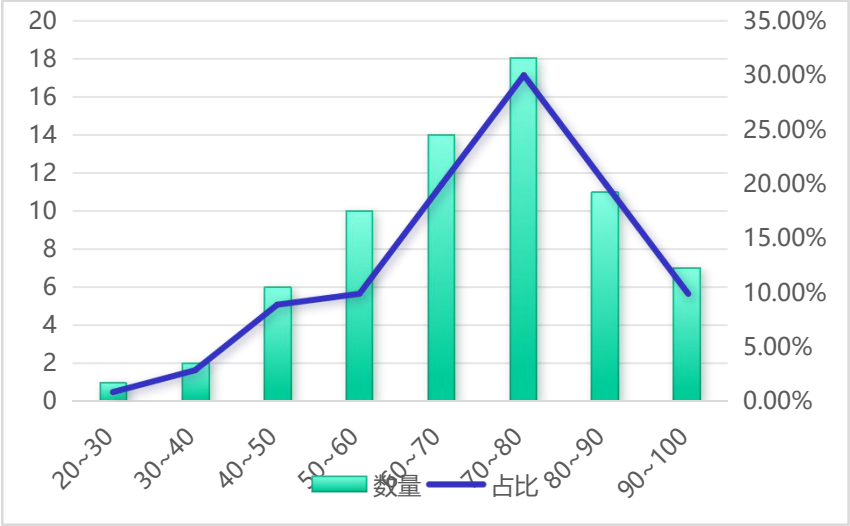

（三）曲线图

n—∞，折线—曲线

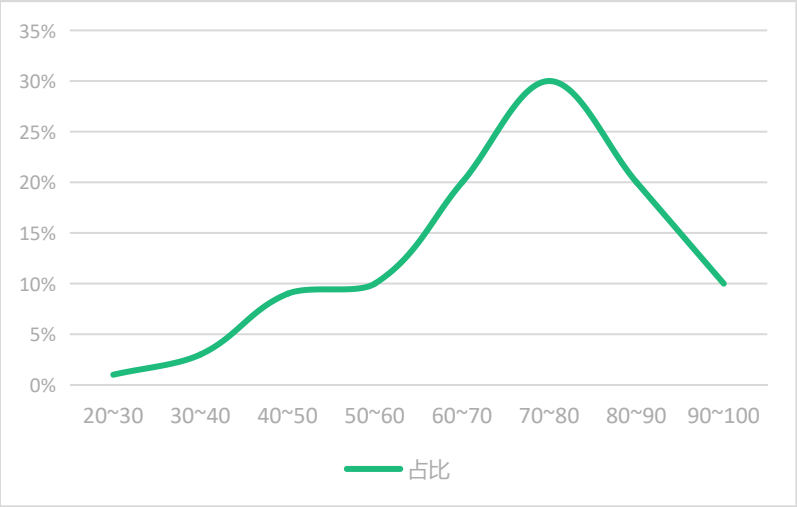

（四）其他图

1. 柱形图

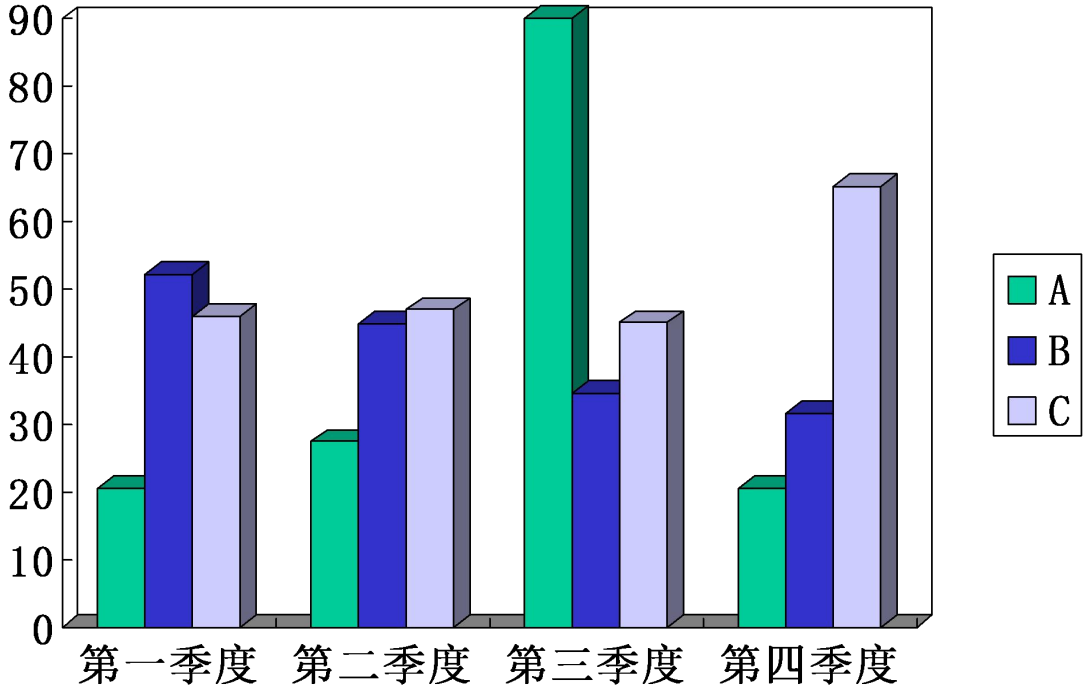

某年某公司三个子公司利润额对比

2. 饼图

受访者性别分布

受访者职业分布

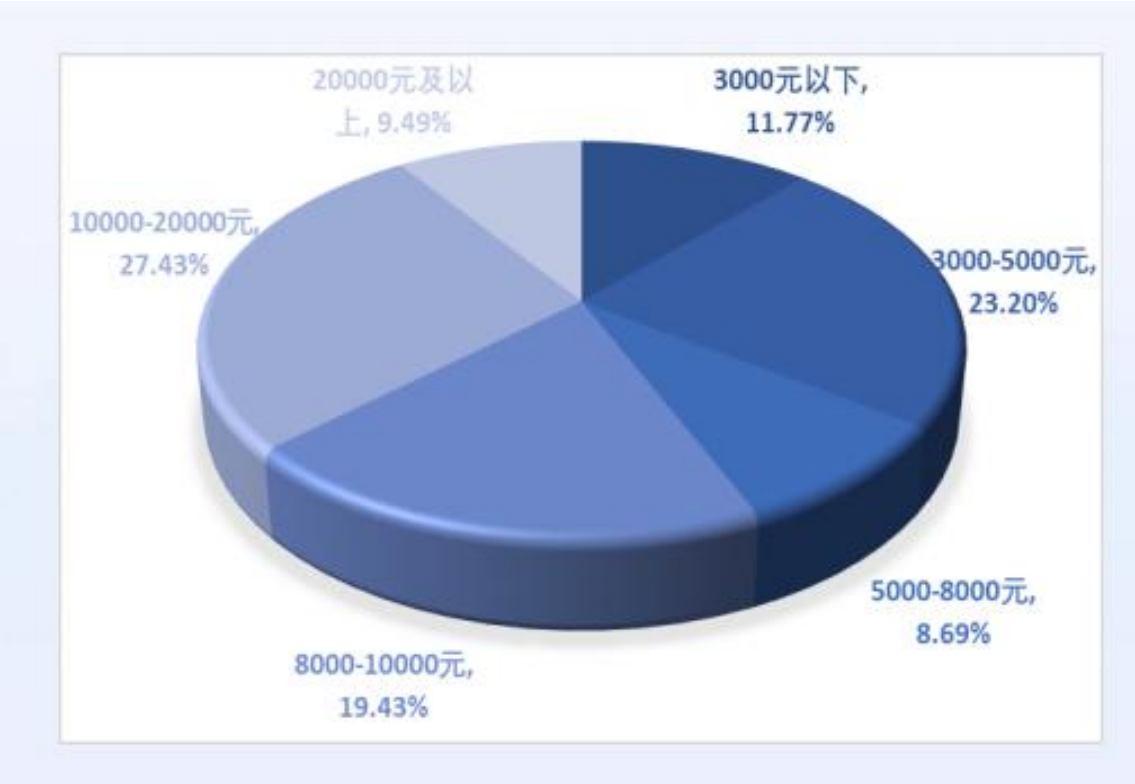
20000元及以上, 9.49%
3000元以下, 11.77%
10000-20000元, 27.43%
3000-5000元, 23.20%
5000-8000元, 8.69%
8000-10000元, 19.43%

受访者月收入分布

3. 环形图

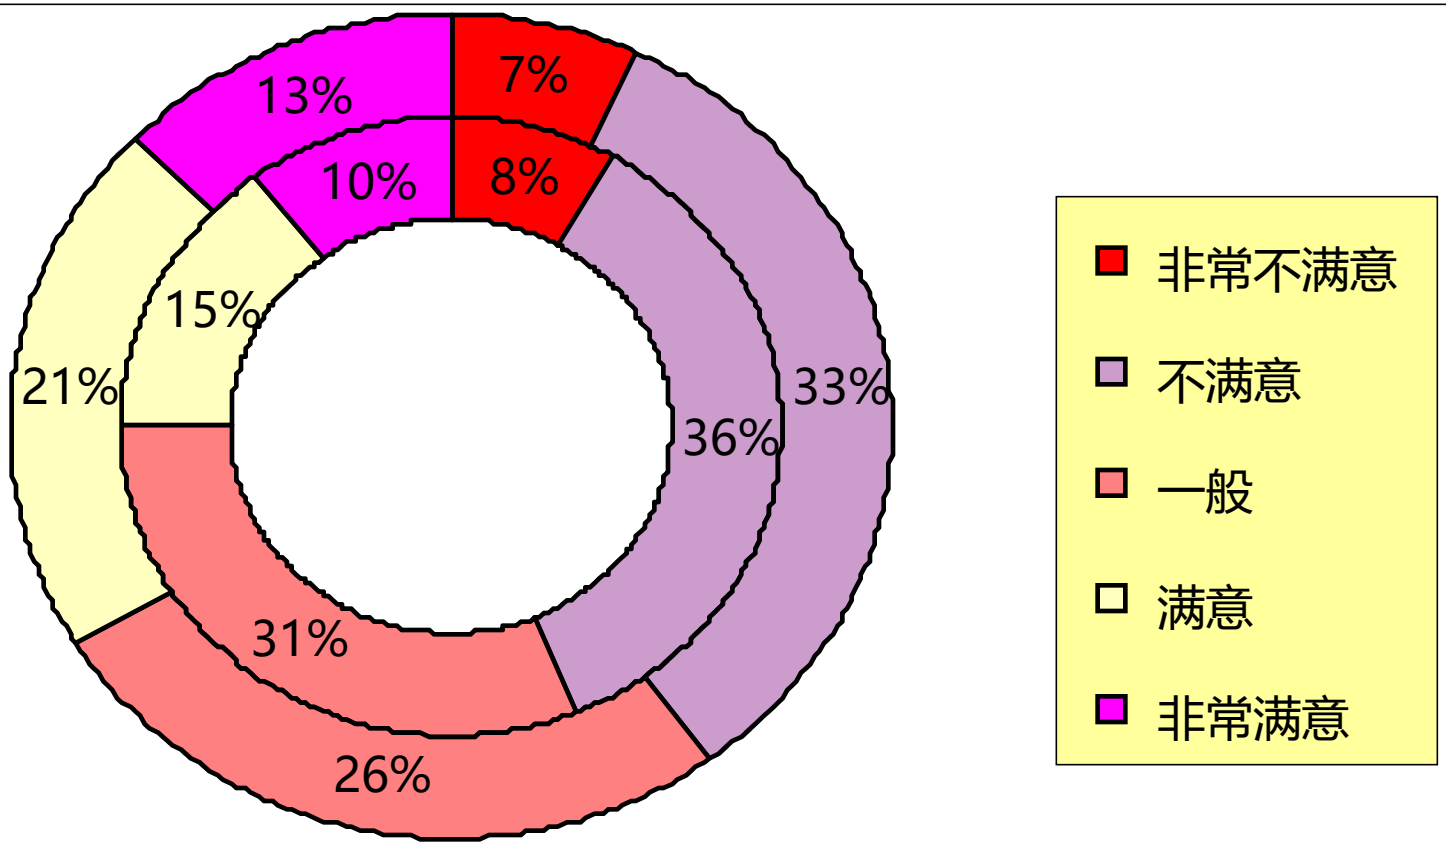

甲乙两城市家庭对住房状况的评价

4. 线图

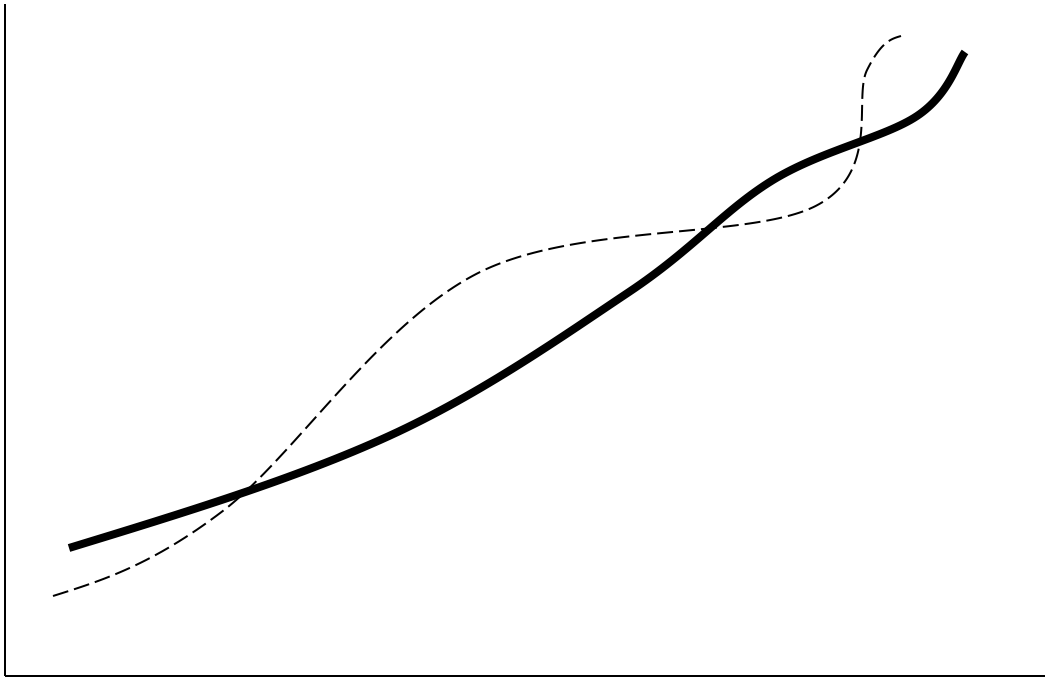

5. 散点图

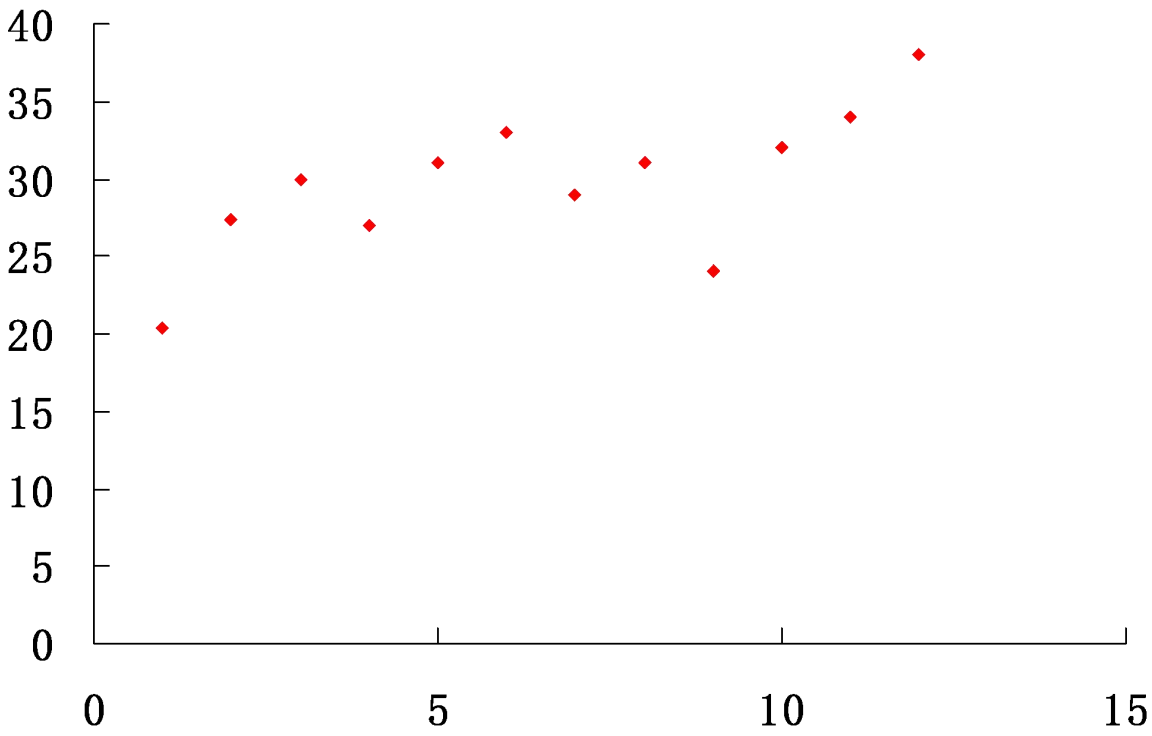

- 补充资料

《数据可视化》课程

课堂练习

1.了解全国人口数量应采用哪一种调查方式（ ）

A.全面调查　　B.抽样调查

C.重点调查　　D.典型调查

2.对居民消费心理的调查宜采用全面调查。（ ）

3.统计调查方案中首要的问题是（ ）

A.确定调查对象　　B.确定调查单位

C.确定调查项目　　D.明确调查目的和任务

4.某班学生按性别和政治面貌层叠分组的结果，男生30人、女生20人；党员3人、团员39人、非党团员8人。这是一种复合分组（ ）

5.在统计分组时，分组标志（ ）

A.只能是品质标志

B.只能是数量标志

C.可以是品质标志也可以是数量标志

D.只能是可变标志

E.只能是不变标志

6.如果要反映某单位职工的文化水平情况，可编制（ ）

A.单项数列 B.品质数列 C.组距数列 D.等距数列

答:

7.连续变量数列其末组为开口组，下限为1000，其相邻组的组中值为950，则末组的组中值为（ ）

A. 1025 B. 1050 C. 1100 D. 1150

答:

8.组距数列中，计算组中值的方法有（ ）

A.（上限+下限）/2　　B. 上限–邻组组距/2

C. 下限+邻组组距/2　　D. 上限+邻组组距/2

E.（上限–下限）/2

9.人口死亡率按年龄分组属哪种次数分布（ ）

A. 钟形分布　　B. 正J形分布

C. U形分布　　D. 反J形分布

10.理论上说，在等距数列中全距等于（ ）和（ ）的乘积

本 章 小 结

- ✓ 统计数据的收集方法
- ✓ 统计误差的概念及类型
- ✓ 统计分组的作用、原则、方法
- ✓ 分布数列
- ✓ 统计图表