第三章　数据分布特征的描述

统计实例

古埃及男性头骨样本的最大宽度

公元前4000年	公元150年
131, 119, 138, 125, 129, 126, 131, 132, 126, 128, 128, 131	136, 130, 126, 126, 139, 141, 137, 138, 133, 131, 134, 129

大量的数据既繁琐又不直观；需要对数据做简化。

用次数分布（图表形式）简化描述⇒只能体现现象的分布规律，但无法精确反映现象内部之间的差异。

定量方法简化描述：

均值：公元前4000年⇒128.67（毫米）

公元150年　　⇒133.33（毫米）

均值差异：133.33–128.67＝4.66（毫米）

结论：1. 智力水平的提高；

2. 古埃及人与来自其他地区的人们通婚的结果。

我们可以用 “平均”、“差距”或百分比等数量方法来概括大量数据。

数据分布特征的描述：总量水平、相对关系、集中趋势、离中趋势、分布形态等。

第一节　总量指标和相对指标

第二节　数据集中趋势的描述

第三节　数据离中趋势的描述

第四节　数据分布形态的描述

第一节　总量指标和相对指标

一、总量指标

1. 总量指标的概念

- 总量指标是反映社会经济现象总规模、总水平、总成果的统计指标。
  - 绝对数的形式表示
  - 是统计资料汇总的直接结果

表 1　某年度国内生产总值及其使用表　　单位：亿元

生产	序号	金额	使用	序号	金额
一、总产出	1	178645	一、总支出	8	178640
二、中间投入	2	110760	二、中间使用	9	110760
三、国内生产总值	3	67885	三、国内生产总值	10	67885
1. 固定资产折旧	4	9504	1．最终消费	11	40004
2. 劳动者报酬	5	37337	(1) 居民消费	12	32152
3. 生产税净额	6	7467	(2) 政府消费	13	7852
4. 营业盈余	7	13577	2．资本形成总额	14	26867
			(1) 固定资本形成总额	15	23336
			(2) 存货增加	16	3531
			3．出口	17	15886
			4．进口	18	14872
			5．统计误差	19	

2. 总量指标的作用

- 总量指标是认识客观现象总体的起点。
- 总量指标是进行科学管理的依据。
- 总量指标是计算相对指标和平均指标的基础。

3. 总量指标的分类

（1）按计量单位不同划分

实物量指标：以实物单位计量的总量指标。自然单位：人、辆等；度量衡单位：吨、米等；标准实物单位：标准吨等；复合单位：顿公里；人次等。

价值量指标：以货币单位计量的总量指标。

劳动量指标：以劳动时间单位来计量的总量指标。如：工时、工日、人年等。

（2）按其反映的内容不同划分

总体单位总量指标：用来反映总体中总体单位数的多少、说明总体本身规模大小的指标。

总体标志总量指标：用来反映总体单位某一数量标志所有标志值的总和，表示其数量规模的指标。

总体单位总量与标志总量的区分，不是固定不变的，而是随着研究目的和研究对象的不同而变化的。

如：

某地区工业企业职工总数是：

总体单位总量指标——以该地区每个工业企业职工为总体单位时

总体标志总量指标——以该地区每个工业企业为总体单位时

（3）按其反映的时间状况不同划分

时期指标：反映现象在一定时期内发展过程的总量。

时点指标：反映现象在某一时刻（瞬间）上状况的总量。

- **时期指标——也称为流量**
  - 反映总体在一段时期内活动过程的总量，
  - 指标数值可以累计相加，
  - 数值大小和时间的长短有直接关系；
- **时点指标——也称为存量**
  - 是反映总体在某一时刻（瞬间）状况的总量
  - 数值不能累计相加，
  - 数值的大小和时间间隔的长短没有直接关系。

练习：试判断下列指标中哪些是时期指标？

- 在校学生人数、招生人数、毕业生人数、出生人数、死亡人数、从业人数、失业人数

二、相对指标

- **1. 概念**
  - ➢两个有联系的指标对比的比率
    - 其指标数值的表现形式为相对数
    - 有两种表现形式
      - 无名数——百分比、千分比、倍数、系数、成数等
      - 有名数——分子与分母的计量单位构成的复名数

例：发展速度、定基（环比）发展速度、增长速度

2. 作用与类型

（1）作用

- 揭示了现象之间的数量联系和对比关系
- 使一些不能直接对比的现象找到共同的比较基础

（2）类型

- 结构相对数
- 比例相对数
- 比较相对数
- 强度相对数
- 计划完成相对数
- 动态相对数

(一) 结构相对数

总体是在同一性质基础上由各种有差异的部分所组成的。结构相对指标就是利用分组法，将总体区分为不同性质(即差异)的各部分，以部分数值与总体数值对比而得出比重或比率，来反映总体内部组成状况的综合指标。其计算公式为

$$\text{结构相对指标}=\frac{\text{总体部分数值}}{\text{总体全部数值}}\times 100\%$$

例：某公司男职工为员工总数的60%，女职工为员工总数的40%，它反映了该公司在男女性别上的构成情况。

（二） 比例相对数

比例相对指标是将总体内某一部分数值与另一部分数值对比所得到的相对数，常用系数或倍数表示。计算公式为

$$\text{比例相对指标}=\frac{\text{总体中某一部分的数值}}{\text{总体中另一部分的数值}}\times 100\%$$

例：我国第6次人口普查结果总人口133972万人，其中：

男、女性别比例为：105.20：100

（三） 比较相对指标

比较相对致也称类比相对数，是将两个同类指标做静态对比得出的综合指标，表明同类现象在不同条件(如在各国、各地、各单位)下的数量对比关系。其计算公式为：

$$\text{比较相对指标}=\frac{\text{某条件下的某类指标数值}}{\text{另一条件下的同类指标数值}}\times 100\%$$

例：某年有甲、乙两企业同时生产一种性能相同的产品，甲企业工人劳动生产率为21776元，乙企业为30994元，求两企业劳动生产率比较相对数。

解：两企业劳动生产率比较相对指标= $\frac{21776}{30994}\times 100\% = 70\%$

（四）动态相对指标

动态相对指标是同类指标在不同时期上的对比，其计算公式为

$$动态相对指标=\frac{报告期水平}{基期水平}\times 100\%$$

- 作为对比标准的时期叫做基期，而同基期比较的时期叫做报告期，有时也称为计算期。
- 动态相对数的计算结果用百分数或倍数表示。

（五） 强度相对指数

强度相对数是两个有联系的不同事物的总量指标数值的对比，因此，分子和分母可以互换，这就产生了有些强度相对数有正指标和逆指标两种

例：某地区占地10.2万平方公里，据统计2018年初和2018年底的人口分别为4216万人和4372万人，2018年国民收入总额为9768亿元，求2018年的人口密度。

解：$$人口密度=\frac{4216万人}{10.2万平方公里}=413(人/平方公里）$$

（六）计划完成相对数

$$计划完成相对指标 = \frac{实际完成数}{同期计划数} \times 100\%$$

1．根据总量指标计算计划完成相对数

例：设某工厂某年计划工业增加值为600万元，实际完成660万元，求增加值计划完成相对数。

解：$增加值计划完成相对数 = \frac{660}{600} \times 100\% = 110\%$

超额的绝对值=660-600=60(万元)

2. 根据平均指标计算计划完成相对指标

根据平均指标计算计划完成相对数的计算公式为：

$$\text{计划完成相对指标} = \frac{\text{实际平均指标}}{\text{计划平均指标}} \times 100\%$$

例：某企业生产某产品，本年度计划单位成本降低9%，实际降低12%，求成本降低率计划完成相对数。

解： 成本降低率计划完成相对数 $= \dfrac{1-12\%}{1-9\%} \times 100\% = 96.7\%$

例：某企业某月生产某产品，计划每人每日平均产量为30件，实际每人每日平均产量为39件，求劳动生产率计划完成相对数。

解：劳动生产率计划完成相对数＝ $\dfrac{39}{30} \times 100\% = 130\%$

3.计算和应用相对指标应注意的问题

（1）正确选择基础

（2）确保可比性

（3）相对数与绝对数结合运用

第二节 统计数据集中趋势的描述

- 统计数据的集中趋势是指一组数据向某一中心值靠拢的倾向。
- 集中趋势描述包括两大类：
  - 数值平均数
  - 位置平均数

一、数值平均数

1. 算术平均数

（1）基本公式

$$\text{算术平均数} = \bar{x} = \frac{\text{总体标志总量}}{\text{总体单位总量}}$$

例：　平均工资=工资总额/职工人数

- 平均成本=总成本/产量

（2）简单算术平均数——未分组时

5名学生的考试成绩分别为（分）：

70、80、80、85、85，

他们的平均成绩是多少？

（70+80+80+85+85）/5=80（分）

$$\overline{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{\sum x}{n}$$

（3）加权算术平均数

——当数据已分组，形成了变量数列：

成绩 x	人数 f
70 80 85	1 2 2
合计	5

平均成绩=（70+80+85）/3 ?

平均成绩=所有人的成绩总和/总人数

=（70+80*2+85*2）/5=80

工人日产量（件）	工人人数（人）	工人人数比重（%）
10	70	8.75
11	150	12.50
12	380	47.50
13	150	18.725
14	100	12.50
合　计	800	100.00

错误的计算：

$$工人平均日产量=\frac{10+11+12+13+14}{5}=\frac{60}{5}=12（件）$$

不符合基本公式，不是5个工人，而是800个工人；工人每日总产量不是60件，而是9710件

所以，应该这样计算：

$$\frac{10\times70+11\times150+12\times350+13\times150+14\times100}{70+150+350+150+100}$$

加权平均数

$$\overline{x} = \frac{x_1 f_1 + x_2 f_2 + \cdots + x_n f_n}{f_1 + f_2 + \cdots + f_n} = \frac{\Sigma xf}{\Sigma f}$$

$$= \frac{9710}{800} = 12.1375$$

工人日产量（件） x	工人日总产量（件） xf
10	700
11	1100
12	4560
13	1950
14	1400
合计	9710

$$\bar{x} = \frac{\sum xf}{\sum \frac{1}{x} xf} = \frac{700 + 1100 + 4560 + 1950 + 1400}{\frac{700}{10} + \frac{1100}{11} + \frac{4560}{12} + \frac{1950}{13} + \frac{1400}{14}}$$

$$= \frac{9710}{800} = 12.1375 \quad \text{（件）}$$

- 调和平均数：只有各组变量值和各组变量值之和的资料时。**当缺乏分子数据时，采用加权平均数；　当缺乏分母数据时，采用调和平均数。**

权数（权重）

——权衡轻重（影响）作用的数（变量）。

权数的两种形式——绝对数（次数）f；

——相对数（比重）

$$\bar{x} = \frac{x_1 f_1 + x_2 f_2 + \cdots + x_n f_n}{f_1 + f_2 + \cdots + f_n} = \frac{\Sigma x f}{\Sigma f}$$

$$\bar{x} = x_1 \frac{f_1}{\Sigma f} + \cdots + x_n \frac{f_n}{\Sigma f} = \Sigma x \frac{f}{\Sigma f}$$

- 切尾平均数：去掉数据大小两端的若干数值后计算中间数据的平均数。

(4) 算术平均数的数学性质

特点：

◆ 算术平均数受变量值和变量值出现次数的共同影响；

◆算术平均数靠近出现次数最多的变量值；

◆算术平均数受极端变量值的影响；

数学性质：

- 变量值与算术平均数的离差和为零。

$$\sum(x-\bar{x})=0 \qquad \sum(x-\bar{x})f=0$$

$$\sum_{i=1}^{n}(x_i-\bar{x})$$

$$=\sum_{i=1}^{n}x_i-\sum_{i=1}^{n}\bar{x}$$

$$=\sum_{i=1}^{n}x_i-n\bar{x}$$

$$=\sum_{i=1}^{n}x_i-\sum_{i=1}^{n}x_i=0$$

- 变量值与算术平均数的离差平方和最小。

$$\Sigma(x-\bar{x})^2 \le \Sigma(x-c)^2 \qquad \Sigma(x-\bar{x})^2 f \le \Sigma(x-c)^2 f$$

证明：设

$$x_0 - \bar{x} = c \ne 0$$

$$\Sigma(x-x_0)^2 = \Sigma[(x-(\bar{x}+c)]^2 = \Sigma[(x-\bar{x})-c)]^2$$

$$= \Sigma(x-\bar{x})^2 - 2c\Sigma(x-\bar{x}) + nc^2$$

$$= \Sigma(x-\bar{x})^2 + nc^2$$

$$\because c \ne 0 \qquad \therefore nc^2 > 0$$

故 $\Sigma(x-x_0)^2 > \Sigma(x-\bar{x})^2$

$$\Sigma(x-\bar{x})^2 = \min$$

2. 几何平均数

- 简单几何平均法

$$\bar{x} = \sqrt[n]{x_1 \cdot x_2 \cdot \cdots\cdots \cdot x_n} = \sqrt[n]{\prod x}$$

- **例：**某流水线有前后五道工序，各工序产品的合格率分别为97%、96%、98%、98.5%、99%，整个流水线的平均合格率为：

$$\bar{x} = \sqrt[5]{0.97 \times 0.96 \times 0.98 \times 0.985 \times 0.99} = 97.69\%$$

- 加权几何平均法

$$\bar{x} = \sum \sqrt[f]{x_1^{f1} \cdot x_2^{f2} \cdots\cdots x_n^{fn}} = \sum \sqrt[f]{\prod x^f}$$

- **例：** 某金融机构以复利计息，近12年的利率有4年为3%，2年为5%，2年为8%，3年为10%，1年为15%，则12年的平均年利率为多少？

$$\bar{x}-1=\sqrt[(4+2+2+3+1)]{1.03^4\cdot 1.05^2\cdot\cdots\cdots 1.15}-1=6.82\%$$

二、位置平均数

- 位置平均数是根据变量值在分布数列中所处的位置来确定的平均数。

1. 众数（Mode）

（1）定义

- 总体中出现次数最多或频率最大的变量值（数据），用 Mo 表示。
- 众数是一种位置平均数，且也不受极端值的影响。

（2）特点

- 不受极端值的影响
- 可能没有众数或有几个众数

（3）适用条件

- 总体单位多；分布有集中趋势

众数(众数的不唯一性)

无众数

原始数据: 10 5 9 12 6 8

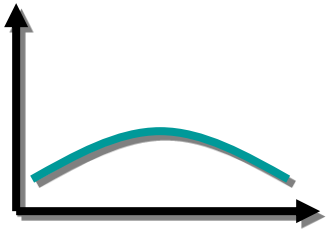

一个众数

原始数据: 6 **5** 9 8 **5** **5**

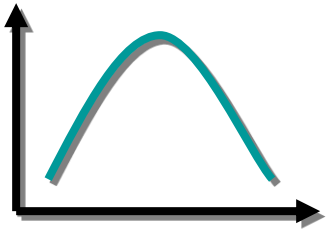

多于一个众数

原始数据: 25 **28** **28** 36 **42** **42**

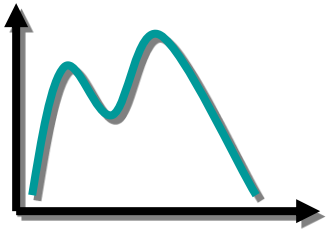

（4）计算方法

- 未分组或者单变量分组的数据
  - 找出出现次数最多的数据即为众数
- 组距数列近似计算众数
  - 找出众数所在组
  - 采用众数计算公式进行计算

——众数的值与相邻两组频数的分布有关

相邻两组的频数不相等时，众数采用下列近似公式计算：

$$M_0 \approx L + \frac{f - f_{-1}}{(f - f_{-1}) + (f - f_{+1})} \times i$$

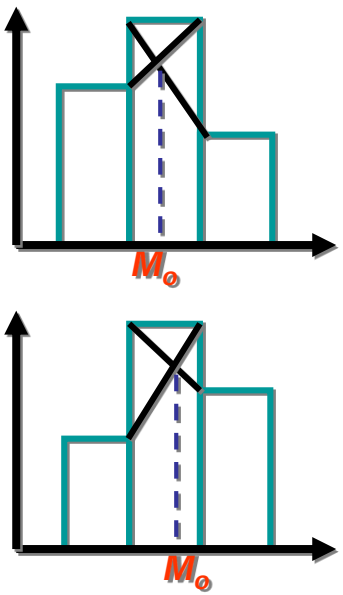

该公式假定众数组的频数在众数组内均匀分布

L 是众数所在组的下限；

f_{-1} 是众数所在组前一组的次数；

f_{+1} 是众数所在组后一组的次数；

f 是众数所在组的次数；

是众数组的组距。

相邻两组的频数相等时，众数组的组中值即为众数

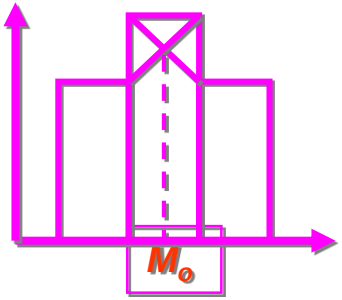

按成绩分组（分）	学生人数（人）
60以下	2
60—70	15
70—80	19
80—90	15
90—100	3
合计	54

$$m_o = L + \frac{f - f_{-1}}{(f - f_{-1}) + (f - f_{+1})} i$$

$$= 70 + \frac{19 - 15}{(19 - 15) + (19 - 15)} \times 10$$

$$= 75$$（分）

公司职工按月工资分组

月工资（元）	职工人数（人）
500以下	208
500-600	314
600-700	382
700-800	456
800-900	305
900-1000	237
1000-1100	78
1100以上	20
合计	2000

$$m_o = L + \frac{\Delta_1}{\Delta_1 + \Delta_2} d$$

$$= 700 + \frac{74}{74 + 151} \times 100$$

$$= 732.89$$ （元）

众数不受极端变量值的影响。

2. 中位数（Median）

（1）定义

将变量值按大小顺序排序，处于中间位置的变量值（或数据）即中位数，用M_e表示。由于中位数是位置代表值，所以不会受极端值的影响，具有较高的稳健性。

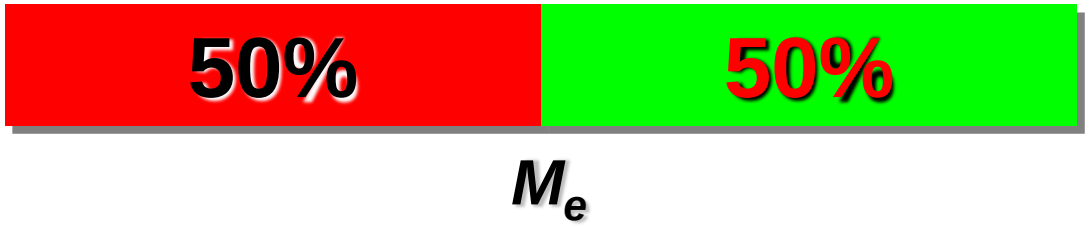

（2）计算方法

– 未分组数据的中位数

$$M_e = \begin{cases} X_{\left(\frac{N+1}{2}\right)} & \text{当}N\text{为奇数时} \\ \frac{1}{2}\left(X_{\frac{N}{2}} + X_{\frac{N}{2}+1}\right) & \text{当}N\text{为偶数时} \end{cases}$$

- 原始数据: 24 22 21 26 20
- 排　　序: 20 21 22 24 26
- 位　　置: 1 2 **3** 4 5

$$\text{位置} = \frac{n+1}{2} = \frac{5+1}{2} = 3$$

$$\text{中位数} = 22$$

组距式数据

可利用 $\frac{\sum f}{2}$ 代替（**n+1**）**/2**，确定中位数所在组，然后根据如

$$M_e = L + \frac{\frac{\sum f}{2} - S_{m-1}}{f_m} \times i$$

Me为中位数，L为中位数组的下限，S_{m-1}为向上累计到中位数所在组以前的次数，f_m为中位数所在组的次数，i为中位数所在组的组距。

- 某乡年人均纯收入中位数计算表如下：

年人均纯收入（元）	农户数	向上累计	向下累计
2000-3000	240	240	3000
3000-4000	480	720	2760
4000-5000	1050	1770	2280
5000-6000	600	2370	1230
6000-7000	270	2640	630
7000-8000	210	2850	360
8000-9000	120	2970	150
9000-10000	30	3000	30
合计	3000	——	——

$$M_e = L + \frac{\frac{\sum f}{2} - S_{m-1}}{f_m} \times i$$

$$M_e = 4000 + \frac{3000 \div 2 - 720}{1050} \times 1000 = 4743(\text{元})$$

（3）算术平均数、中位数和众数的关系

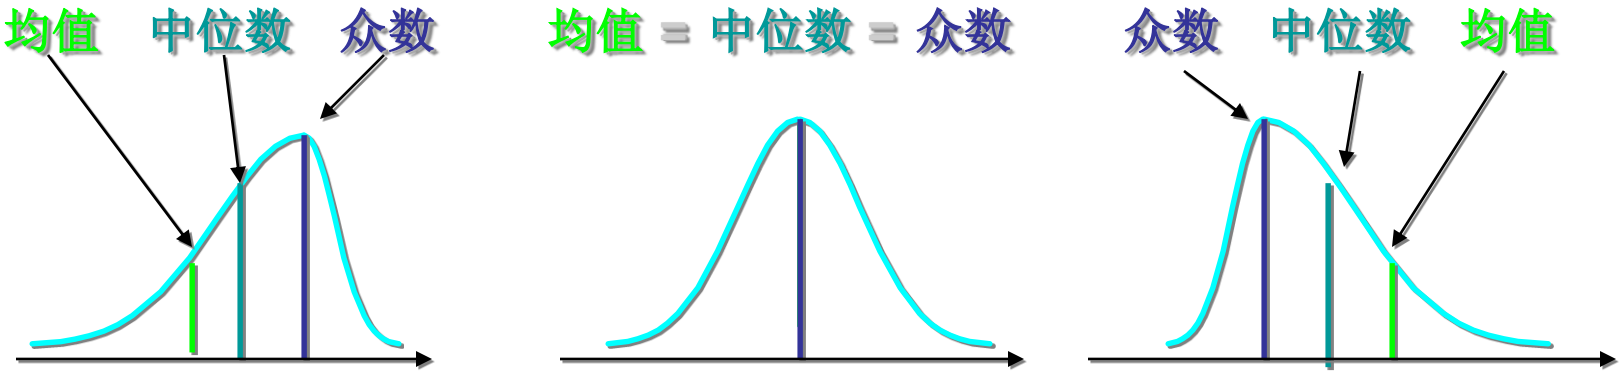

左偏分布　　对称分布　　右偏分布

3. 分位数

- 中位数是从中间点将全部数据分为两部分。与中位数类似的还有四分位数、十分位数、百分位数。
- 四分位数就是对数据集合四等分的三个数值，其中的第二个四分位数即为中位数。

例：某数据集合有101项数据，则第26项、51项、76项三个数据可以把数据集合分为数目相等的四个等分，这三个数就分别是第一、第二、第三四分位数，其中第一个四分位数称为下四分位数，第三个四分位数称为上四分位数，第二个四分位数就为中位数。

三、计算和应用平均指标应注意的问题

- 同质性——基本原则
- 与分组结合
- 与变异指标结合

第三节 统计数据的离中趋势

- 一、变异指标

衡量集中趋势代表性的尺度，数据越分散，变异指标值越大，集中趋势的代表性越差。主要的指标由**极差、四分位差、平均差、标准差、离散系数**等。

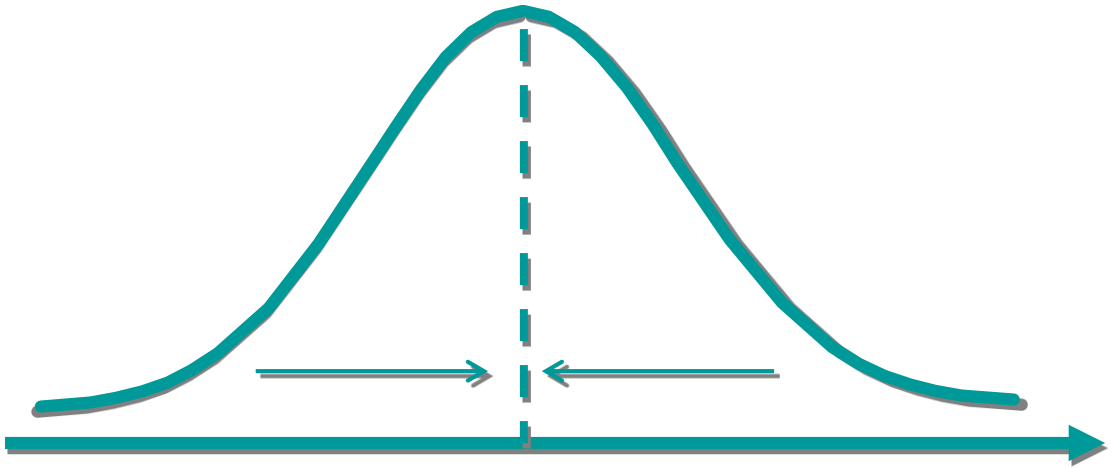

例： 你是一家制造业公司的供应部门经理，与两家原材料供应商联系供货，**两家供应商均表示能在大约10个工作日内供齐所需原材料**。几个月的运转之后，你发现尽管两家供货商供货的平均时间都是大约10天，**但他们供货所需天数的分布情况却是不同的**（见下页图）。你认为两家供货商按时供货的可信度相同吗？考虑它们直方图的差异，你更愿意选择哪家供货商供货呢？

两家供货商供货图

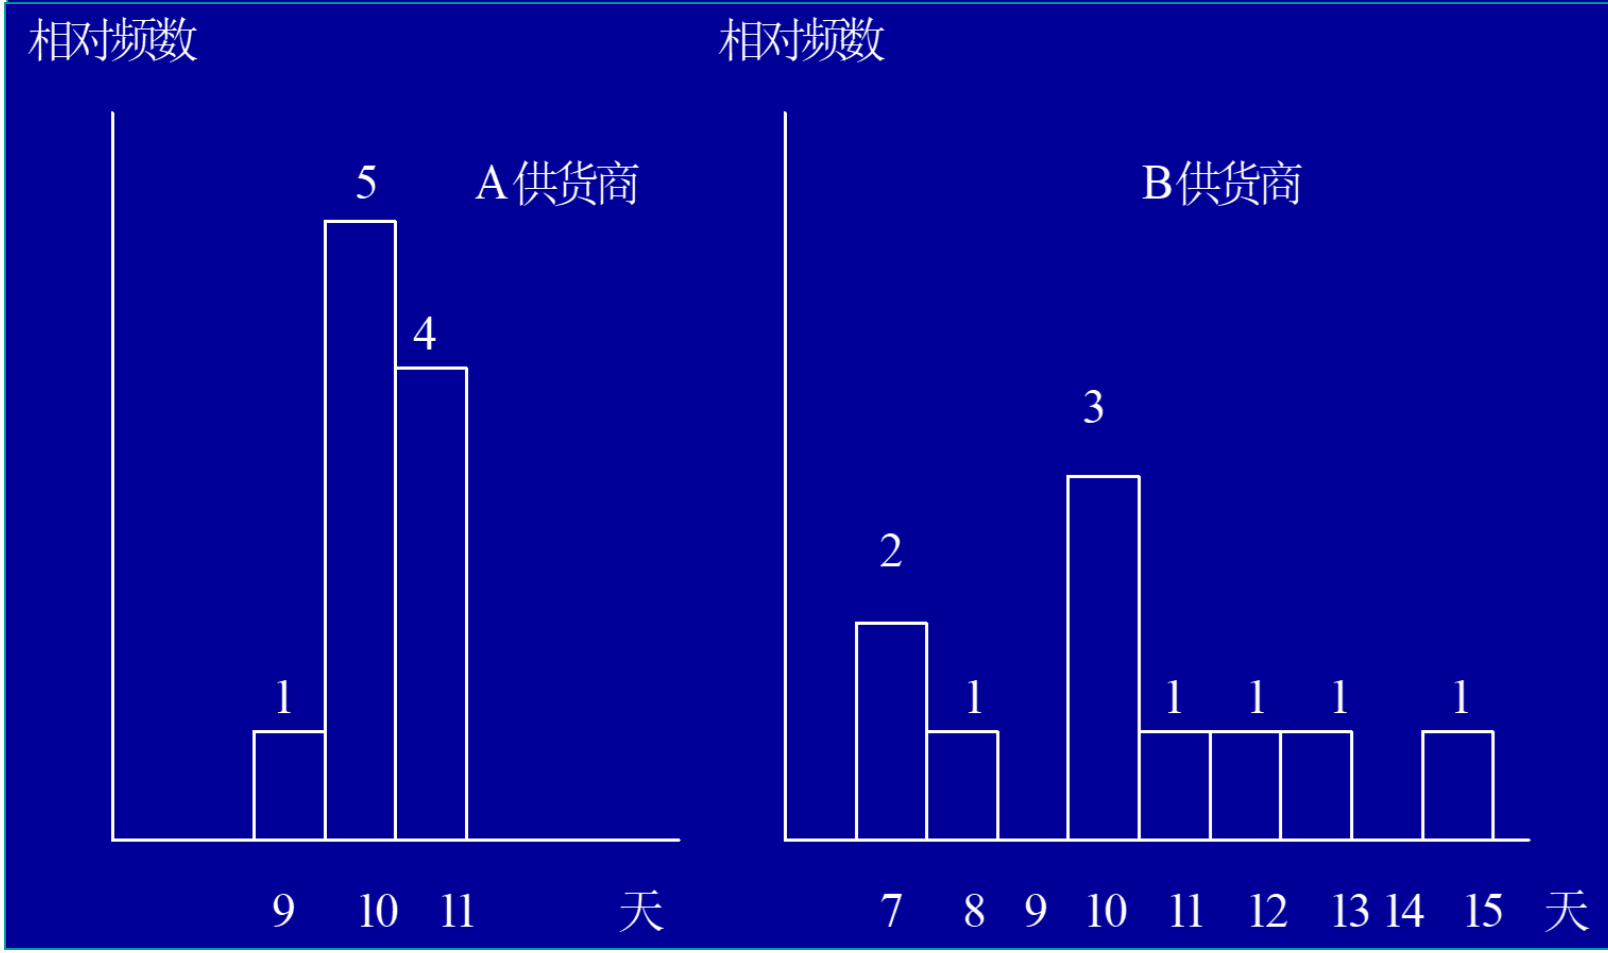

1. 极差与四分位差

R=最大值－最小值

极差越小，表明资料越集中，集中趋势统计量的代表性越高。

四分位差： **也称为内距或四分间距，它是上四分位数与下四分位数之差。**

计算方法

①求出上四分位数和下四分位数的位置

②计算这两个四分位数之差

◆ 对原始资料

调查11位同学的年龄如下：17岁、18岁、18岁、19岁、19岁、20岁、20岁、21岁、21岁、22岁、22岁。

首先，求出Q1和Q3的位置：

Q1的位置= $\frac{n+1}{4}=\frac{11+1}{4}=3$

Q3的位置= $\frac{3(n+1)}{4}=\frac{3\times(11+1)}{4}=9$

其次，从数序中找出Q1=18，Q3=21

则四分位差Q= Q3－Q1=21－18=3

- 四分位差反映了50%数据的离散程度，其数值越小，说明中间数据越集中，反之则越分散。
- 四分位差可以用于反映定序数据的离散程度，但不适合于定类数据。

2. 平均差（Average Deviation）

变量值与平均数的离差绝对值的平均数

$$A.D = \frac{\sum |x - \bar{x}|}{n}$$

$$A.D = \frac{\sum |x - \bar{x}| f}{\sum f}$$

3. 方差Variance和标准差S.D

测度标志变异最重要，最常用的指标。

方差：变量值与平均数的离差平方的平均数。

标准差：方差的平方根。

$$\sigma^2 = \frac{\sum (x-\bar{x})^2}{n} \qquad \sigma^2 = \frac{\sum (x-\bar{x})^2 f}{\sum f}$$

$$\sigma = \sqrt{\frac{\sum (x-\bar{x})^2}{n}} \qquad \sigma = \sqrt{\frac{\sum (x-\bar{x})^2 f}{\sum f}}$$

方差和标准差的数学性质

（1）若每一个变量值加上一个常数，方差和标准差不变

（2）若每一个变量值均扩大一个常数倍，则方差扩大为常数的平方倍，标准差扩大为常数的绝对值倍。

（3）分组条件下，总方差可以分解成组内方差的平均数$\overline{\sigma^2}$和组间方差 δ^2 两部分，即：

$$\sigma^2 = \overline{\sigma^2} + \delta^2$$

其中

$$\overline{\sigma^2} = \frac{\sum_{i=1}^{m} \sigma_i^2 f_i}{\sum_{i=1}^{m} f_i} \qquad \delta^2 = \frac{\sum_{i=1}^{m} (\overline{x}_i - \overline{x})^2 f_i}{\sum_{i=1}^{m} f_i}$$

$$\overline{x_i} = \frac{\sum_{j=1}^{f_i} x_{ij}}{f_i} \qquad \sigma_i^2 = \frac{\sum_{j=1}^{f_i} (x_{ij} - \overline{x_i})^2}{f_i}$$

$$i = 1,2,3,\cdots,m$$

总方差、组间方差和组内方差之间关系

总方差＝组间方差与组内方差平均数之和

$$\sigma^2 = \delta^2 + \overline{\sigma_i^2}$$

举例给以解释

假如:某班级同学50名，每月分别消费（元）

3000、3400、3100、5000、6000、…

计算50名同学之间差异，也就是总的方差。即为总方差。

如果把这50名按男女性别分为两组，

男生组月消费额求得的方差，即为组内方差；

女生组月消费额求得的方差，即为组内方差；

男女两组之间求得的方差即为组间方差。

例：某工厂实行早、中、晚三班工作制。工厂管理部门想了解不同班次工人劳动效率是否存在明显的差异。每个班次随机抽出了7个工人，得工人的劳动效率（件/班）资料如表。分析不同班次工人的劳动效率是否有显著性差异。

早班	中班	晚班
34	49	39
37	47	40
35	51	42
33	48	39
33	50	41
35	51	42
36	51	40

总平均劳动效率为：

$$\bar{y} = \left(\sum_{i=1}^{k} \sum_{j=i}^{n_i} y_{ij} \right) / n$$

$$= \frac{34 + 37 + \cdots + 42 + 40}{21} = 41.571$$

三个班次工人的平均劳动效率分别为：

$$\bar{y}_1 = 34.714 \qquad \bar{y}_2 = 49.571 \qquad \bar{y}_3 = 40.429$$

总离差平方和SS

$$\sum_{i=1}^{k}\sum_{j=1}^{n_i}(y_{ij}-\bar{y})^2$$

$$= (34-41.571)^2 + (37-41.571)^2 + \cdots + (40-41.571)^2$$

$$= 825.1429$$

组间离差平方和(条件误差)SS_A

$$\sum_{i=1}^{k} n_i(\bar{y}_i-\bar{y})^2$$

$$7\times(34.714-41.571)^2 + 7\times(49.571-41.571)^2$$

$$+ 7\times(40.429-41.571)^2 = 786.286$$

组内离差平方和（随机误差）SS_e

$$\sum_{i=1}^{k}\sum_{j=1}^{n_i}(y_{ij}-\bar{y}_i)^2$$

$$=(34-34.714)^2+\cdots+(36-34.714)^2$$

$$+(49-41.571)^2+\cdots+(51-41.571)^2$$

$$+(39-40.429)^2+\cdots+(40-40.429)^2=38.857$$

$$825.1429=786.286+38.857$$

（4）同一数列的标准差一般不小于平均差

4. 离散系数与异众比率

一群牛的平均体重是180公斤，标准差是18公斤；一群羊的平均体重是15公斤，标准差是3公斤，能不能说羊的平均体重的代表性高些？为什么？

全距、平均差、方差和标准差有计量单位，是标志变异的绝对指标。 而且指标的大小不仅取决于变量值的差异程度，还取决于变量值水平的高低。因而，对于具有不同水平的数列，或不同量纲的数列，都不能直接用全距、平均差、方差和标准差来比较平均数代表性的大小。只能用相对形式——变异系数（离散系数）——进行比较。

离散系数包括：

全距系数 $v_R = \dfrac{R}{\bar{x}}$

平均差系数 $v_{AD} = \dfrac{A.D}{\bar{x}}$

标准差系数 $v_\sigma = \dfrac{\sigma}{\bar{x}}$

离散系数适合于：

- 比较不同标志的变异程度
- 当同一个标志在多个总体具有不同的平均水平时，要评价和比较哪个总体的平均水平具有较好的代表性时。
- 前例：

一群牛的平均体重是180公斤，标准差是18公斤；一群羊的平均体重是15公斤，标准差是3公斤，能不能说羊的平均体重的代表性高些？为什么？

异众比率

1. 离散程度的测度值之一
2. 非众数组的频数占总频数的比重
3. 计算公式为：

$$V_r = \frac{\sum F_i - F_m}{\sum F_i} = 1 - \frac{F_m}{\sum F_i} = 1 - \frac{\text{众数组次数}}{\text{总次数}}$$

4. 用于衡量众数的代表程度

异众比率越大说明非众数组的频率占总频数的比重越大，数据越分散。

某城市居民关注广告类型的频数分布		
广告类型	人数(人)	频率(%)
商品广告	112	56.0
服务广告	51	25.5
金融广告	9	4.5
房地产广告	16	8.0
招生招聘广告	10	5.0
其他广告	2	1.0
合计	200	100

$$V_r = \frac{200 - 112}{200}$$

$$= 1 - \frac{112}{200}$$

$$= 0.44 = 44\%$$

这说明在所调查的200人当中，关注非商品广告的人数占44%，异众比率还是比较大。因此，用“商品广告”来反映城市居民对广告关注的一般趋势，其代表性还不是很好

	定类数据	定序数据	定量数据 （定距和定比数据）
集中趋势	众数	众数 中位数 四分位数据	众数 中位数 四分位数 算术平均 几何平均
离中趋势	异众比率	异众比率 四分位差	异众比率 四分位差 极差、平均差、标准差和方差

第四节 数据分布形态的测定

1. k阶矩

- X关于a的k阶矩：

$$\frac{\sum (x-a)^k}{n}$$

当a=0时得到k阶原点矩。

一阶原点矩为算术平均数，二阶原点矩为变量平方的算术平均数。

？当a为x的算术平均数时，k=1，和k=2分别是多少，表示什么含义？

2. 偏态

（1）由中心矩测定偏态

- 中心矩：当a取x的均值时，即为k阶中心矩，用m_k表示。
- 在对称分布中，k为奇数，m_k=0；
- 在非对称分布时，m_1=0，其他m_k则不等于0；
- 由于三阶矩最简单，因此常用三阶矩来测定偏态。

$$SK = \frac{m_3}{\sigma^3}$$

对称分布的sk=0；当sk为正值，为右偏分布，sk为负值为左偏分布。

（2）由均值与众数（中位数）的关系来测定

$$SK = \frac{\bar{x} - m_0}{\sigma}$$

对称分布的sk=0；当sk为正值，为右偏分布，sk为负值为左偏分布。

（3）由三个四分位数之间的关系来测定

$$SK = \frac{Q_U + Q_L - 2M_e}{Q_U - Q_L}$$

3. 峰态(kurtosis)

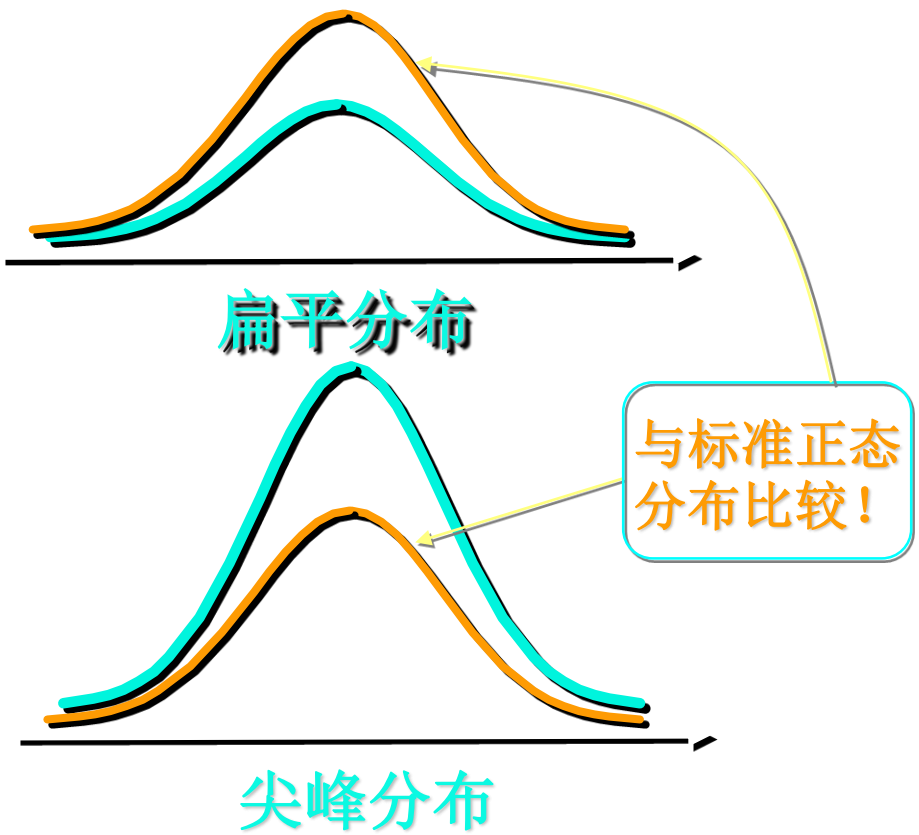

- 统计学家Pearson于1905年首次提出。数据分布峰值的高低
- 计算公式

$$\alpha_4 = \frac{\sum_{i=1}^{K}(X_i - \overline{X})^4 F_i}{\sigma^4 \sum_{i}^{K} F_i}$$

经验表明，上述峰度系数为3时，恰为正态分布曲线，因此，

- 当峰度系数<3时，为平顶分布曲线；
- 当峰度系数>3时，为尖顶分布曲线；
- 当峰度系数接近于1.8时，则频数分布曲线趋向于一条水平线；
- 当峰度系数小于1.8时，为U型曲线。

课堂练习

1. 某商店50名职工的工资资料如下，试按各组职工人数和他们的比重分别计算平均工资，并计算中位数与众数。

按月工资分组（元）	职工人数（人）	人数比重（%）
500 以下	5	10
500—600	10	20
600—700	20	40
700—800	8	16
800 以上	7	14
合计	50	100

答：654元/人，M_e=650元，M_o=645.45元

2. 三个企业计划完成情况及一等品率资料如下：

企业	计划产量（件）	完成计划%	实际一等品率%
A	300	102	99
B	500	105	97
C	200	97	95

试求：（1）三个企业平均产量计划完成百分比；

（2）三个企业实际平均一等品率。

$$\text{解：三个企业产量计划完成程度} = \frac{\text{实际产量}}{\text{计划产量}}$$

$$= \frac{1.02\times300+1.05\times500+0.97\times200}{300+500+200} = \frac{\Sigma xf}{\Sigma f} = \frac{1025}{1000} = 102.5\%$$

$$解:实际平均一等品率=\frac{实际一等品数量}{实际产量}$$

$$=\frac{0.99\times300\times1.02+0.97\times500\times1.05+0.95\times200\times0.97}{300\times1.02+500\times1.05+200\times0.97}=\frac{\Sigma xf}{\Sigma f}$$

$$=\frac{996.49}{1025}=97.22\%$$
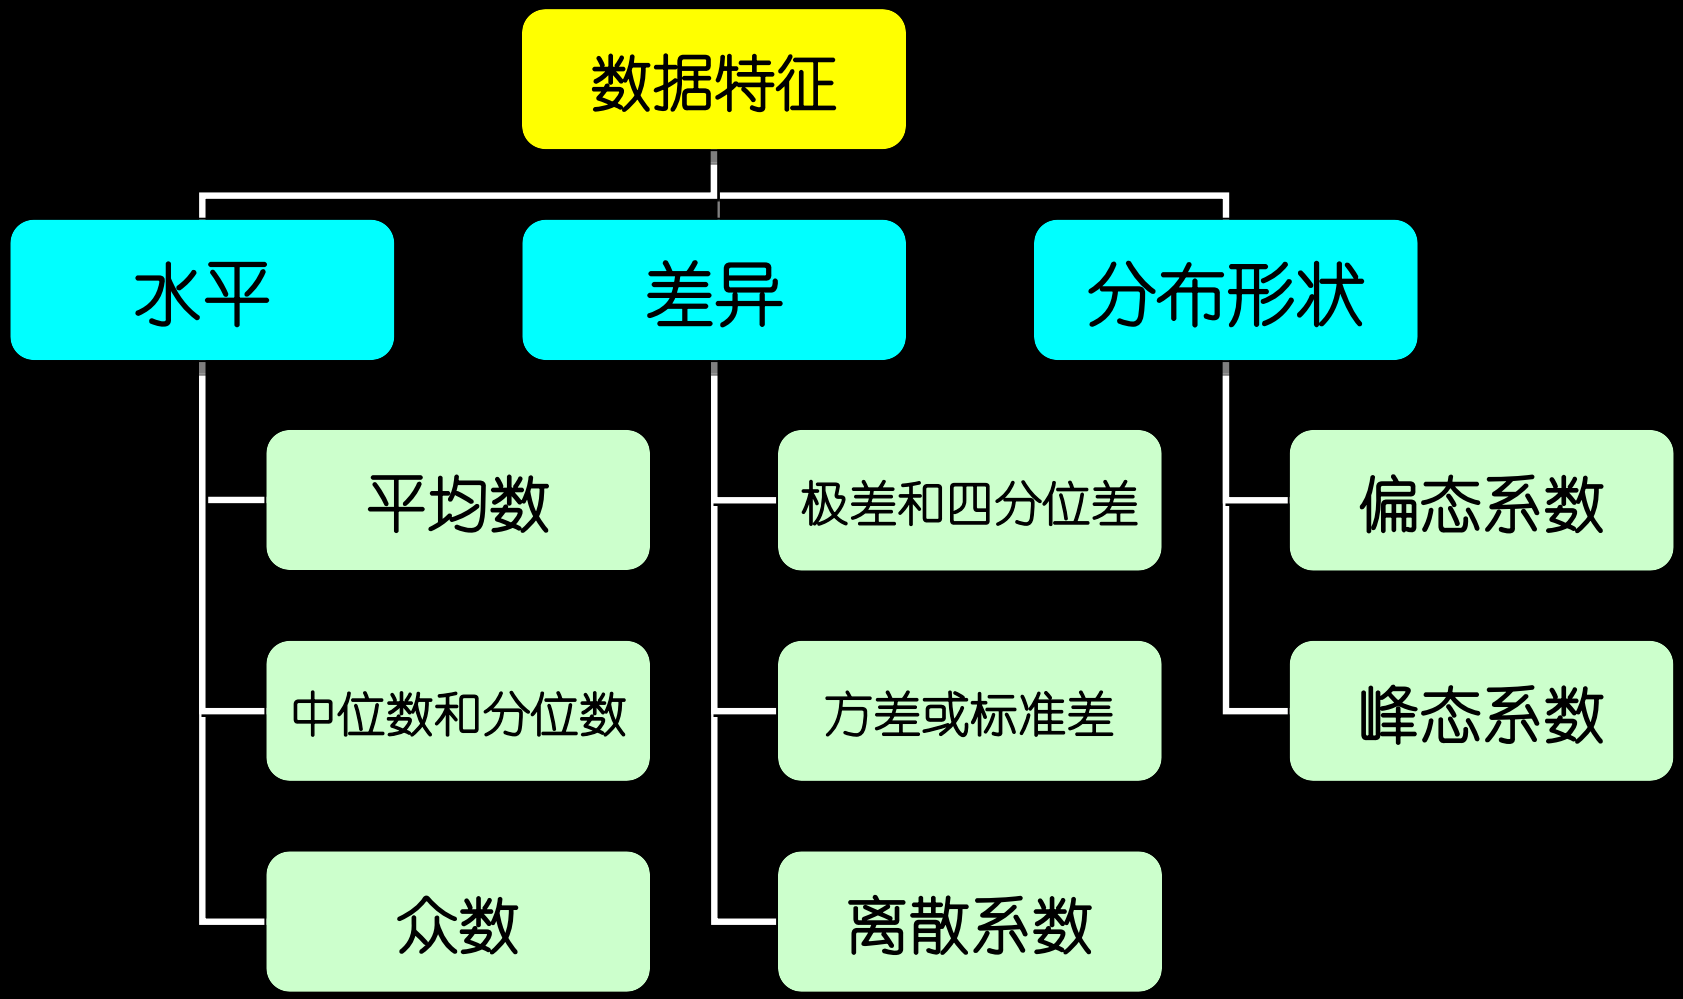
本章小结